

# Spark mit Windows 10

<https://phoenixnap.com/kb/install-spark-on-windows-10>

Anleitung zur Installation von Apache Spark auf Windows 10. Dies bildet die Basis für den Einfachen Einsatz und Nutzung durch Sprachen wie Kotlin oder C# (Auch das geht, wie man hier sieht: <https://docs.microsoft.com/de-de/dotnet/spark/what-is-apache-spark-dotnet>)

Für die Nutzung von Spark bedarf es mindestens vier Vorgaben:

1. Java muss in einer neueren Version installiert sein
2. Python muss in einer neueren Version installiert sein
3. Apache Spark selbst muss installiert sein
4. Zudem muss die Zusammenarbeit mit Hadoop berücksichtigt werden

***Hinweis: In den Abbildungen tauchen zum Teil unterschiedliche Versionen der Software auf. Dies ist darauf zurückzuführen, dass ich an zwei Rechnern jeweils unterschiedliche Versionen installiert habe und die Screenshots während dieser beiden Installationen entstanden.***

## Java

Mit Hilfe des Befehls `java -version` kann die aktuell installierte Version überprüft werden. Gleichzeitig ist so sichergestellt, dass die Systemvariablen für Java korrekt eingestellt wurden:

```
PS C:\> java -version
java version "1.8.0_261"
Java(TM) SE Runtime Environment (build 1.8.0_261-b12)
Java HotSpot(TM) Client VM (build 25.261-b12, mixed mode)
PS C:\>
```

Ist Java auf dem System installiert erscheint eine Meldung ähnlich der oben zu sehenden. Hier im Beispiel ist die Version 1.8 installiert, welche aktuell ist.

Sollte dies nicht der Fall sein, so kann unter <https://java.com/en/download/> eine aktuelle Version installiert werden. Hier findet man auch die entsprechenden Schritte zur Installation.

## Python

Mit Hilfe des Befehls `python --version` kann die Version der installierten Python Version abgerufen werden. Auch hier signalisiert der erfolgreiche Aufruf, dass die Umgebungsvariablen gesetzt wurden.

```
PS C:\> python --version
Python 3.9.6
PS C:\> |
```

In diesem Fall ist die aktuelle Version 3.9.6 vorhanden. Für den Fall, dass Python nicht installiert ist, können die notwendigen Installationsdatei und Anleitung auf der Seite von <https://www.python.org> abgerufen werden. Der Download selbst befindet sich beispielsweise hier: <https://www.python.org/downloads/release/python-396/> (hier für die Version 3.9.6).

## Spark

<https://spark.apache.org/downloads.html>

Die notwendigen Dateien finden sich an der oben genannten Adresse. Hier kann unter anderen die Release Version sowie der Typ eingestellt werden. An dieser Stelle wird die Auswahl wie nachfolgend zu sehen getroffen:

### Download Apache Spark™

1. Choose a Spark release:
2. Choose a package type:
3. Download Spark: [spark-3.0.3-bin-hadoop3.2.tgz](#)
4. Verify this release using the 3.0.3 [signatures](#), [checksums](#) and [project release KEYS](#).

Über den an Punkt 3 gezeigten Link gelangt man zu einer Seite mit verschiedenen Mirrors, wobei der oberste in der Regel eine gute Wahl darstellt.

---

We suggest the following mirror site for your download:

<https://mirror.checkdomain.de/apache/spark/spark-3.0.3/spark-3.0.3-bin-hadoop3.2.tgz>

Other mirror sites are suggested below.

Nach dem Download kann die heruntergeladene Datei mit Hilfe der Checksumme verifiziert werden. Hierzu folgt man den unter Punkt 4 angegebenen Link zur Checksumme:

← → ↻ 🔒 [downloads.apache.org/spark/spark-3.0.3/spark-3.0.3-bin-hadoop3.2.tgz.sha512](https://downloads.apache.org/spark/spark-3.0.3/spark-3.0.3-bin-hadoop3.2.tgz.sha512)

Apps Google Kalender Virtuelle Fachhochs... WEB.DE - E-Mail-A...

spark-3.0.3-bin-hadoop3.2.tgz: 22FC9A60 42769D13 C01F3B07 F0DFAE9D 5D1E4082  
44870833 C5E703EB 43669CE1 4C875F7C EC47A07F  
1CF2EE3E 65DFB136 39776448 CD686481 CCC0E071  
5D2760D5




Mit dem Befehl **certutil** kann nun die Checksumme aus der heruntergeladenen Datei generiert und mit der angezeigten verglichen werden. Hierbei sollte darauf geachtet werden, dass die Versionen zueinander passen, da es leicht zu Verwechslungen kommen kann.

```
PS C:\> certutil -hashfile c:\users\username\Downloads\spark-3.0.3-bin-hadoop3.2.tgz SHA512
CertUtil: -hashfile-Befehl ist fehlgeschlagen: 0x80070002 (WIN32: 2 ERROR_FILE_NOT_FOUND)
CertUtil: Das System kann die angegebene Datei nicht finden.
PS C:\> certutil -hashfile C:\Users\ckitte\Downloads\spark-3.0.3-bin-hadoop3.2.tgz SHA512
SHA512-Hash von C:\Users\ckitte\Downloads\spark-3.0.3-bin-hadoop3.2.tgz:

22fc9a6042769d13c01f3b07f0dfae9d5d1e408244870833c5e703eb43669ce14c875f7cec47a07f1cf2ee3e65dfb1363977644bcd686481ccc0e0715d2760d5
CertUtil: -hashfile-Befehl wurde erfolgreich ausgeführt.
PS C:\> |
```

Die Installation von Spark ist eigentlich ein Entpacken der heruntergeladenen Datei in ein frei zu bestimmendes Verzeichnis. Für das Entpacken kann das normale und in Windows vorhandene ZIP Tool verwendet werden.

Nach dem Entpacken der tgz Datei, existiert eine neue Datei mit der Endung tar. Hierbei handelt es sich um ein gezipptes Verzeichnis. Nachdem diese Datei ebenfalls entpackt wurde, liegt das eigentliche Verzeichnis vor:

<input type="checkbox"/> Name	Änderungsdatum	Typ	Größe
 spark-3.0.3-bin-hadoop3.2	17.06.2021 06:51	Dateiordner	
 spark-3.0.3-bin-hadoop3.2.tar	07.07.2021 15:32	TAR-Datei	245.320 KB
 spark-3.0.3-bin-hadoop3.2.tgz	07.07.2021 15:32	TGZ-Datei	219.496 KB

In dem angelegten Ordner befinden sich alle zu Spark gehörenden Dateien, welche nun verfügbar sind.

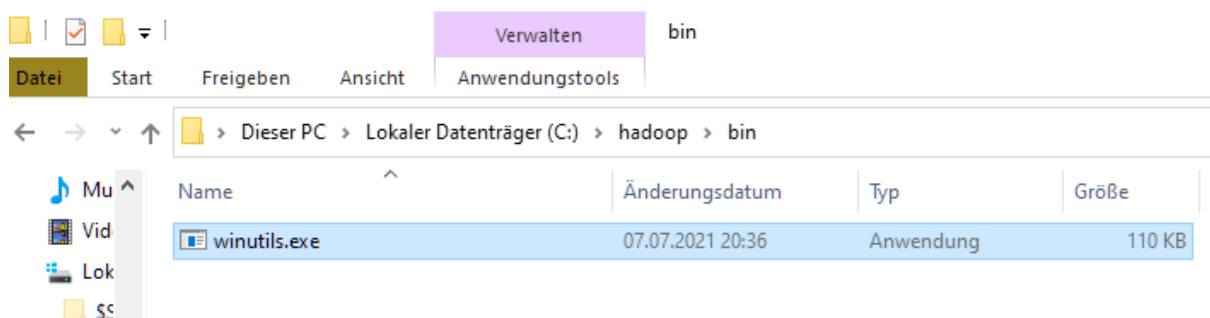
Spark baut auf Hadoop auf. die hier verwendete Version 3.2 wurde beim Download (siehe oben) ausgewählt. Zum Betrieb unter Windows muss jedoch keine komplette Hadoop Umgebung realisiert werden. Allerdings wird unter Windows ein kleines Tool benötigt, da Hadoop Probleme mit dem Dateiverzeichnis von Windows hat.

Das Tool kann unter <https://github.com/cdarlint/winutils> passend für die gewählte Version herunter geladen werden.

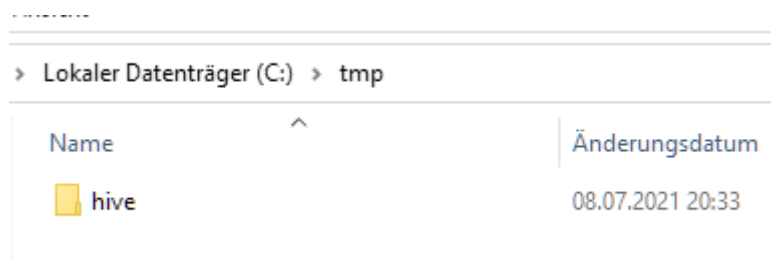
master winutils / hadoop-3.2.1 / bin /

cdarlint add 321 winutils ...

Hierzu wird in das passende Verzeichnis auf GitHub gegangen und die Datei winutils.exe heruntergeladen. Diese wird anschließend in einem Verzeichnis c:\hadoop\bin hinein kopiert.



Weiter benötigt Hadoop nach Aussage einiger Quellen für das korrekte Funktionieren ein temporäres Verzeichnis unter c:\tmp\hive zur Speicherung von Zwischenwerte. Diese Aussage konnte jedoch nicht sicher geprüft werden.



Das angelegte Verzeichnis muss für winutil verfügbar sein. Dies erreicht man durch das Ausführen des folgenden Kommandos:

```
PS C:\Users\Christian Kitte> winutils chmod 777 c:\tmp\hive
PS C:\Users\Christian Kitte> |
```

Abschließend müssen im nächsten Schritt noch einige Pfade angepasst werden, damit alle Komponenten zusammenarbeiten können. Die folgenden Umgebungsvariablen müssen hierbei festgelegt, sowie die Pfadvariablen entsprechend erweitert werden:

**SPARK\_HOME**

**c:\spark\spark-3.1.3-bin-hadoop3.2**

**Path ergänzen mit %SPARK\_HOME%\bin**

**HADOOP\_HOME**

**C:\hadoop**

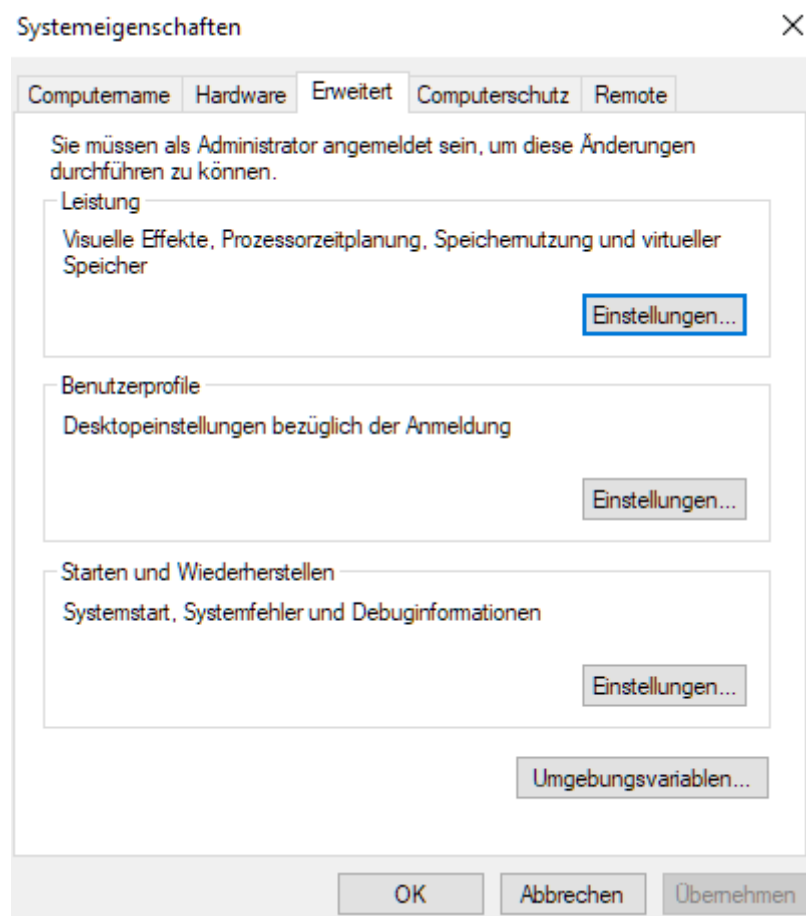
**Path ergänzen mit %HADOOP\_HOME%\bin**

**JAVA\_HOME**

**c:\Program Files (x86)\Java\jre1.8.0\_291 (jre reicht)**

**keine Pfad**

Für die Umsetzung wechselt man über **System** in **Systemeigenschaften** und hier in die Bearbeitung der **Umgebungsvariablen** (Button unten rechts auf dem Reiter "Erweitert"):



Im Anschluss sollten alle Umgebungsvariablen verfügbar sein (hier in Powershell):

```
PS C:\> $env:SPARK_HOME
c:\spark\spark-3.1.2-bin-hadoop3.2
PS C:\> $env:HADOOP_HOME
c:\hadoop
PS C:\> $env:JAVA_HOME
C:\Program Files (x86)\Java\jre1.8.0_291
PS C:\> |
```

und hier in der normalen Eingabeaufforderung:

```
C:\Users\Christian Kitte>echo %SPARK_HOME%
c:\spark\spark-3.1.2-bin-hadoop3.2


C:\Users\Christian Kitte>echo %HADOOP_HOME%
c:\hadoop

C:\Users\Christian Kitte>echo %JAVA_HOME%
C:\Program Files (x86)\Java\jre1.8.0_291
```

Somit ist nunmehr die Installation abgeschlossen. mit dem Befehl **spark-shell** lässt sich die Konsole von Spark aufrufen;

```
PS C:\> C:\spark\spark-3.1.2-bin-hadoop3.2\bin\spark-shell
PS C:\> |
```


Nach der Bestätigung öffnet sich eine neue Konsole und Spark startet mit einer Reihe von Ausgaben.



## Christian Kitte


Lokales Konto

Anmelden




OneDrive

OneDrive konfigurieren



Windows Update

Letzte Überprüfung: vor 47 Minuten




Prämien

Anmelden

```

C:\WINDOWS\system32\cmd.exe
21/07/07 20:56:47 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using b
asses where applicable
Using Spark's default log4j profile: org/apache/spark/log4j-defaults.properties
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
Spark context Web UI available at http://host.docker.internal:4040
Spark context available as 'sc' (master = local[*], app id = local-1625684214360).
Spark session available as 'spark'.
Welcome to

```



The image shows the Spark logo, which is a stylized 'S' composed of several small, interconnected geometric shapes. To the right of the logo, the text 'version 3.1.2' is displayed.

```

Using Scala version 2.12.10 (OpenJDK 64-Bit Server VM, Java 1.8.0-25)
Type in expressions to have them evaluated.
Type :help for more information.

scala> 21/07/07 20:57:06 WARN ProcsMetricsGetter: Exception when trying to compute pagesize, as a result
rocessTree metrics is stopped

```

Gleichzeitig ist die shell Web UI von Spark über den Browser am standardmäßigen Port 4040 erreichbar:

Spark shell - Spark Jobs

localhost:4040/jobs/

APACHE  
Spark 3.1.2

Jobs

Stages

Storage

Environment

Executors

## Spark Jobs (?)

**User:** Christian Kitte

**Total Uptime:** 3,8 min

**Scheduling Mode:** FIFO

[▶ Event Timeline](#)